

CONSTRUCCIÓN DE UN CLÚSTER DISTRIBUIDO CON DOCKER, HADOOP Y SPARK

Índice de **C O N T E N I D O S**

- 1.** Objetivo del proyecto
- 2.** Docker contra Máquinas Virtuales
- 3.** HDFS
- 4.** Apache Spark
- 5.** PySpark
- 6.** Nuestro Sistema

1. OBJETIVO DEL PROYECTO

Tenemos:

- Equipos individuales
- Procesamiento local

Queremos:

- Infraestructura distribuida
- Procesamiento paralelo
- Arquitectura escalable

2 . D O C K E R C O N T R A M Á Q U I N A S V I R T U A L E S

Máquina Virtual (VM)

Sistema operativo completo
Más pesada
Mayor consumo de RAM y CPU

V S

Contenedor Docker

Comparte kernel del host
Mucho más ligero
Arranque en segundos
Ideal para clústeres


Usamos **Docker** porque permite simular un clúster distribuido de forma ligera, rápida y eficiente, sin necesidad de crear múltiples máquinas virtuales completas.

3 . H D F S

HDFS (Hadoop Distributed File System) es el sistema de almacenamiento principal de Hadoop, pensado para manejar grandes volúmenes de datos en hardware estándar.

¿Cómo funciona?

- Divide archivos en bloques.
- Distribuye los bloques entre los nodos.
- Replica datos para evitar pérdidas.



Componentes:

- NameNode: Almacena la estructura de directorios y metadatos.
- DataNodes: Almacena bloques de datos.

HDFS es clave en Big Data porque permite procesamiento paralelo con frameworks como **Spark**.

4 . A P A C H E S P A R K

Apache Spark es un motor de procesamiento distribuido que permite analizar grandes volúmenes de datos en paralelo usando múltiples nodos.

¿Cómo funciona?

- El trabajo se divide en partes pequeñas.
- Se envían a varios nodos (Workers).
- Cada nodo procesa una parte.
- Se combinan los resultados

Componentes:

- Master
- Worker

Esto permite más velocidad, menos consumo de recursos y mayor escalabilidad.



R D D


Un **RDD** (Resilient Distributed Dataset) es la estructura de datos básica de Spark que almacena información de forma distribuida, inmutable y tolerante a fallos.

¿Cómo funciona?


- Spark divide los datos en particiones.
- Cada partición se envía a un Worker.
- Cada Worker procesa su parte.
- Se combinan los resultados.

Componentes

- **Transformaciones:** construyen un plan de trabajo.
- **Acciones:** ejecutan el plan en el cluster.



ARQUITECTURA MÁSTER-WORKER



Master

Coordina el clúster
Asigna tareas
Gestiona recursos

Workers

Ejecutan los cálculos
Procesan datos
Reportan al Master

5 . P Y S P A R K

PySpark es la API de Python para Apache Spark que permite ejecutar procesamiento distribuido en un clúster utilizando código Python.

Ventajas:

- Permite ETL y análisis de datos.
- Integración con entornos Big Data.
- Procesamiento en memoria.
- Escalable.
- Evaluación perezosa (Lazy Evaluation)



PySpark permite usar la potencia de Spark con la simplicidad de Python.

6. NUESTRO SISTEMA

ArchivoEditarVerHistorialMarcadoresPerfilesHerramientasAyuda

Contenido / [M()] - COMPUTPresentación Diapositivas PropuSpark Master at spark://spark-m

http://localhost:8080110%Iniciar sesión

4.0.1

Spark Master at spark://spark-master:7077

URL: spark://spark-master:7077

Workers: 2 Alive, 0 Dead, 0 Decommissioned, 0 Unknown

Cores in use: 2 Total, 0 Used

Memory in use: 2.0 GiB Total, 0.0 B Used

Resources in use:

Applications: 0 Running, 0 Completed

Drivers: 0 Running (0 Waiting), 0 Completed (0 Killed, 0 Failed, 0 Error, 0 Relaunching)

Status: ALIVE (Environment, Log)

Workers (2)

Worker Id	Address	State	Cores	Memory
worker-20260224165905-172.20.0.3-41847	172.20.0.3:41847	ALIVE	1 (0 Used)	1024.0 MiB (0.0 B Used)
worker-20260224165905-172.20.0.4-36769	172.20.0.4:36769	ALIVE	1 (0 Used)	1024.0 MiB (0.0 B Used)

Running Applications (0)

Application ID	Name	Cores	Memory per Executor	Resources Per Executor	Submitted Time	User	State	Duration
----------------	------	-------	---------------------	------------------------	----------------	------	-------	----------

Completed Applications (0)

Application ID	Name	Cores	Memory per Executor	Resources Per Executor	Submitted Time	User	State	Duration
----------------	------	-------	---------------------	------------------------	----------------	------	-------	----------

The image features a light teal background with a dark teal border. The corners are decorated with layered, folded paper effects in shades of teal. Centered on the page is the text "MUCHAS GRACIAS" in a dark teal, sans-serif font. "MUCHAS" is in a regular weight, while "GRACIAS" is in a bold weight.

MUCHAS
GRACIAS