



SP6: Feature Engineering

Isabel Pelaya Galindo Ibáñez
Esther Ibáñez Mingorance
José Luis López García
Juan Rafael Madolell Usero





Índice



- 1. Feature Engineering**
- 2. StringIndexer**
- 3. OneHotEncoder**
- 4. VectorAssembler**
- 5. StandardScaler**
- 6. MLPipeline**
- 7. Feature Selection (Correlación)**
- 8. Resultados**
- 9. Problemas**

1. FEATURE ENGINEERING

¿Qué es Feature Engineering?

Preparar y transformar los datos para que puedan ser utilizados por modelos de Machine Learning.

Los modelos **no** trabajan directamente con datos en bruto, por lo que es necesario convertirlos a un formato numérico y estructurado.

En muchos datasets encontramos problemas como:

- Variables categóricas en formato texto
- Valores numéricos en escalas muy diferentes
- Datos que no están preparados para ser usados por un modelo

2. STRINGINDEXER

¿Qué es?

Una técnica que permite convertir variables categóricas en valores numéricos.

A cada categoría se le asigna un número, normalmente en función de su frecuencia en el dataset.

¿Para qué sirve?

Para transformar datos de texto en un formato que el modelo puede empezar a procesar.

3. ONEHOTENCODER

¿Qué es?

Proceso para transformar cada valor en un vector binario.

¿Para qué sirve?

Para representar cada categoría de forma independiente, evitando que el modelo interprete relaciones que realmente no existen.

Soluciona que la asignación de los números del método StringIndexer pueda interpretarse como si existiera un orden entre ellos.

4. VECTORASSEMBLER

¿Qué es?

Proceso para combinar todas las variables del dataset en una única columna llamada “features”.

Este paso es necesario porque los modelos de Spark MLlib trabajan con una única entrada en formato vectorial.

¿Para qué sirve?

Hace que las variables queden agrupadas y listas para ser utilizadas por el modelo.

5. STANDARDSCALER

¿Qué es?

Proceso que transforma los datos para que tengan una media de 0 y una desviación estándar de 1.

¿Para qué sirve?

Para que todas las variables queden en una escala similar y contribuyan de manera equilibrada al modelo.

6. ML PIPELINE

Un ML Pipeline permite automatizar todos los pasos anteriores en un único flujo de trabajo.

Cómo funciona?

- En lugar de aplicar cada transformación manualmente, se encadenan todas en un proceso ordenado.

Ventajas:

- Facilita la reutilización del código, mejora la organización y reduce la posibilidad de errores.

7. FEATURE SELECTION (CORRELACIÓN)

No todas las variables aportan valor al modelo. Algunas pueden ser irrelevantes o estar duplicando información.

¿Cómo funciona?


- Mediante técnicas como la correlación, se pueden identificar variables que están muy relacionadas entre sí.

Ventajas:

- Eliminar estas variables ayuda a simplificar el modelo y mejorar su rendimiento.

8. RESULTADOS

Impacto de Variables (Correlación de Pearson)



Variable seleccionada:
Productividad

8. RESULTADOS

Comparativa de tiempos usando las tablas con más correlación vs todas las tablas

```
=====
BENCHMARK DE RENDIMIENTO Y PRECISIÓN (R2)
=====

>>> Test: USANDO TODO
✓ Tiempo: 16.6288s | R2 (Precision): 1.0000

>>> Test: USANDO SOLO MEJORES (Feature Selection)
✓ Tiempo: 5.4279s | R2 (Precision): 1.0000

=====
CONCLUSIÓN FINAL
=====

Pérdida de precision: 0.00%
Ganancia de velocidad: 67.36%
=====
```

8. RESULTADOS

Vector de características

```
Productividad (Label): 33.779998779296875
Vector (Features): [-0.32978579500700345,-0.36896848304595065,-1.422712315309548,-0.8664074822769243,1.5770284791292437,-0.7321446691595486,0.6773684228948632,-0.38404168711575865,1.0366460641128505,-0.9590142249933946]
-----
Productividad (Label): 48.9900016784668
Vector (Features): [0.32281383311472417,-0.7654769578446361,0.030644358770672214,-0.2325565803800798,1.5770284791292437,1.2256154989398844,1.0670387329310516,1.3588860941409315,-0.9646011639042353,1.0426852636173223]
-----
Productividad (Label): 36.599998474121094
Vector (Features): [-0.10009984575414729,-1.3106761106928286,-1.6049978015338329,-0.4287485639000832,-1.2134006794074201,-0.3912897300387028,1.1783731072271053,-1.6289901022991087,1.0366460641128505,-0.9590142249933946]
-----
Productividad (Label): 19.8700008392334
Vector (Features): [-0.7526994738758749,-0.7159133984948004,-0.9546822636349479,1.1498422369570866,0.1818138998609117,-1.6920565495015294,-0.49860090560720494,0.3629273619942514,1.0366460641128505,-0.9590142249933946]
-----
Productividad (Label): 52.900001525878906
Vector (Features): [0.8806225421794212,-1.1619854326433217,-0.15164100999352592,-0.9750676821215595,0.1818138998609117,-1.403508174735985,1.2966658799166624,0.11393767895758136,-0.9646011639042353,1.0426852636173223]
-----
Productividad (Label): 47.310001373291016
Vector (Features): [0.7019778570341969,0.27535778850191317,-1.4769053453195058,-0.6732339056063421,1.5770284791292437,-1.2856745104114526,0.9904963506025145,0.6119170450309214,-0.9646011639042353,-0.9590142249933946]
-----
Productividad (Label): 41.22999954223633
Vector (Features): [1.3873899871364863,-1.4593667887423356,-0.07774146632906975,1.5693910020885218,0.8794211894950776,-1.5201919984667693,-1.1318151594160109,1.6078757771776016,1.0366460641128505,-0.9590142249933946]
-----
Productividad (Label): 53.810001373291016
Vector (Features): [0.40666742535724265,-0.2698413643462793,-0.8167364331332848,-0.8875358984461913,0.1818138998609117,0.3030657635200443,-0.6795192638382923,-1.3800004192624387,1.0366460641128505,-0.9590142249933946]
-----
Productividad (Label): 25.989999771118164
Vector (Features): [-0.3881186682728684,-1.2611125513429928,-0.8118099221797468,1.0291085536403273,-0.8645970345903372,-1.4460430674550575,1.4636674413607431,1.3588860941409315,-0.9646011639042353,1.0426852636173223]
-----
Productividad (Label): 73.18000030517578
Vector (Features): [0.7384360766710377,0.42404846655142026,1.4987812704720263,-1.2436997029209462,1.5770284791292437,0.5289612012650323,1.1574979120465951,-0.13505200407908866,1.0366460641128505,-0.9590142249933946]
-----
```

9. PROBLEMAS

Falta de Librerías (Pandas):

El problema: El script falló porque en el Docker no estaba instalado pandas, que usábamos para las gráficas.

La solución: Se rescribió el código para que funcionara solo con Spark y Matplotlib, que son las librerías que sí estaban disponibles.

9. PROBLEMAS

Variables categóricas:

El problema: Intentar meter el género ("Male", "Female") directamente en el VectorAssembler da un error porque Spark ML solo entiende vectores numéricos.

La solución: Tuvimos que añadir obligatoriamente las etapas de StringIndexer (para pasar a números 0 y 1) y OneHotEncoder (para que el modelo no piense que el 1 es "mejor" que el 0). Sin esto, el Pipeline fallaría siempre.

**Muchas
gracias**

