



SP7: Machine Learning Distribuido

Isabel Pelaya Galindo Ibáñez
Esther Ibáñez Mingorance
José Luis López García
Juan Rafael Madolell Usero





Índice



- 1. Aprendizaje Supervisado**
- 2. Train, Test y Crossvalidation**
- 3. Métricas de Evaluación**
- 4. Algoritmos de Machine Learning**
- 5. Procesamiento Avanzado**
- 6. Modelos Avanzados**
- 7. Resultados**
- 8. Problemas**

1. APRENDIZAJE SUPERVISADO

¿Qué es?

Una técnica donde el modelo se entrena utilizando datos previamente etiquetados.

¿Cómo funciona?

El modelo aprende patrones a partir de ejemplos reales repartiendo el trabajo entre varios nodos.


2. TRAIN, TEST Y CROSSVALIDATION

¿Qué es?

- **Train y Test:** Consiste en dividir los datos en un 80% para entrenamiento y un 20% para test de pruebas.
- **Crossvalidation:** evalúa el modelo varias veces con diferentes particiones de los datos para obtener un resultado más fiable.

¿Para qué sirve?

Sirve para asegurarnos de que el modelo funciona bien y no solo con un conjunto de datos concreto.



3. MÉTRICAS DE EVALUACIÓN

¿Qué son?

Son medidas que indican la calidad y precisión de un modelo.

Ejemplos:

- **RMSE:** mide el error en modelos de regresión.
- **R^2 :** indica el grado de ajuste del modelo

4. ALGORITMOS DE MACHINE LEARNING


¿Qué son?

Técnicas que permiten al sistema aprender de los datos y hacer predicciones.

Ejemplos:

- **Regresión Lineal:** Predice valores numéricos.
- **Árbol de Decisión:** Se basa en reglas lógicas.
- **Random Forest:** Combina múltiples árboles para mejorar la precisión.

4. ALGORITMOS DE MACHINE LEARNING



5. PROCESAMIENTO AVANZADO

¿Qué es?

Es una forma de procesar datos de manera más eficiente usando código personalizado.

Ejemplo:

- **Pandas UDF:** Es una función que permite aplicar operaciones personalizadas sobre grandes volúmenes de datos en Spark, utilizando Pandas de forma eficiente.

6. MODELOS AVANZADOS


¿Qué es?

Son modelos de Machine Learning más complejos que permiten captar patrones difíciles o más profundos en los datos.

Ejemplo:


- **LSTM:** Modelo que aprende patrones en datos que cambian con el tiempo.
- **Autoencoders:** Modelo que simplifica los datos para encontrar patrones ocultos.

7. RESULTADOS




7. RESULTADOS



Matriz de Confusión — Árbol de Decisión
(Baja / Media / Alta)



Importancia de Features
(Árbol de Decisión)




7. RESULTADOS




7. RESULTADOS

Importancia de Features
(Gradient Boosting)



Gradient Boosting — Reales vs Predichos (val)





7. RESULTADOS

Tabla comparativa de modelos (ordenada por Test R²):

	Modelo	CV R ² ± std	CV RMSE (mean)	Test R ²	Test RMSE	Test MAE
0	Reg. Lineal	1.0000 ± 0.0000	0.0029	1.0000	0.0029	0.0025
1	Gradient Boosting	0.9968 ± 0.0001	0.9111	0.9970	0.8791	0.6939
2	Random Forest	0.9813 ± 0.0008	2.1997	0.9830	2.0943	1.6373
3	Árbol Decisión	0.7921 ± 0.0036	7.3352	0.7948	7.2698	5.8397

7. RESULTADOS



8. PROBLEMAS

Problema: Overfitting

El modelo memoriza los datos en lugar de aprender, haciendo que funcione muy bien en los entrenamientos pero que en los test no se de las respuestas esperadas.

Solución: Early Stopping, que detiene el entrenamiento cuando el modelo deja de mejorar para evitar el sobre aprendizaje.

**Muchas
gracias**

